將 XGBoost 應用於糖尿病預測問題

一、導論

糖尿病為現代常見慢性疾病之一，若未及早發現並治療，可能引發多種併發症。因此，建立有效的糖尿病預測模型，對於國人健康相當重要。本研究以機器學習方法的 XGBoost（eXtreme Gradient Boosting）為核心，利用具有多種健康與生活型態特徵的資料集，進行糖尿病預測，並且使用 K-fold 交叉驗證(CV)來比較各個參數的表現，期望最終挑選出效能最佳的模型進行預測。

二、相關文獻回顧

監督式機器學習預測已有大量相關研究，常見模型包含決策樹（Decision Tree）（Breiman et al., 1984）、隨機森林（Random Forests）（Breiman, 2001）及梯度提升（Gradient Boosting）（Friedman, 2001）。Extreme Gradient Boosting（XGBoost）(Chen, Guestrin, 2016）是一種高效能梯度提升機器（Gradient Boosting Machine）演算法，它保持傳統的 Boosting 架構，又結合了多種系統與演算法層面的優化技術，使其在分類與回歸問題中具有極高的效能與彈性。此外，對於類別不平衡的資料單純以準確率（Accuracy）或 f1-score 評估效果將造成偏誤，因此需要搭配 Macro F1-score 等其他指標來評估表現。

三、資料與方法

3.1 資料集簡介

本研究使用一筆包含 21 個特徵的糖尿病相關資料集，變數名稱如下：
"HighBP", "HighChol", "CholCheck", "BMI", "Smoker", "Stroke", "HeartDiseaseorAttack", "PhysActivity", "Fruits", "Veggies","HvyAlcoholConsump", "AnyHealthcare", "NoDocbcCost", "GenHlth","MentHlth", "PhysHlth", "DiffWalk", "Sex", "Age", "Education", "Income"

透過檢視變數名稱及其取值範圍，判斷該特徵為數值型變數（如 BMI、Age、PhysHlth）或是類別型變數（如 Smoker、HighChol、GenHlth）。資料整合後

將類別欄位轉換為 factor，數值欄位則保留原型。目標變數 Label 表示病人是否患有糖尿病，分析的結果很明顯不平衡，其中約 87% 為非糖尿病個體。

3.2 資料前處理

- 檢查是否有缺失值：無缺失值。
- 將類別欄位轉換為 factor 以利於後續機器學習訓練。
- 曾對數值型欄位進行 log-transform，但經 Random Forest 模型畫出變數對於預測的貢獻度，發現未能改善預測效果，故最終未使用。
- 為因應不平衡資料，預測機率不以 0.5 為分類門檻，而設定了可以調整的參數 thres 作為分類門檻機率。
- 所有模型皆採 5-fold 交叉驗證進行參數選擇與誤差估計。

3.3 XGBoost 模型

XGBoost 是 Gradient Boosting(GBM)的改良版，一樣是透過多棵決策數逐步學習減少模型預測誤差，但是相較於 GBM，多了正則化項(L1/L2)，可以有效防止過擬和。

四、實驗與比較

本研究一共嘗試過十種機器學習模型：

1. Linear Discriminant Analysis (LDA)
2. Quadratic Discriminant Analysis (QDA)
3. LDA with cost-sensitive adjustment
4. QDA with cost-sensitive adjustment
5. Classification Tree
6. Random Forests
7. Neural Networks
8. Support Vector Machine (SVM)
9. Gradient Boosting (GBM)
10. Extreme Gradient Boosting (XGBoost)

4.1 模型表現觀察

- **LDA 與 QDA（無 cost 調整）** 表現普遍不佳(0.60 及 0.62)，與 baseline(0.67) 差距明顯。

- **LDA with cost** 表現優於 QDA with cost(0.66 對 0.62)，已經相當接近 baseline。但是能夠調整的參數只有 cost matrix，無法繼續優化。
- **Classification Tree** 雖快速但表現有限，使用 Random Forests 理應更佳
- **Random Forests** 為 **Classification Tree** 的改良版，但是不適合使用 K-fold 交叉驗證，為了方法的一致性，決定尋找下一個方法。
- **SVM** 的應用多是在影像辨識、圖像辨識，和當前任務不同，暫且擱置
- **NN** 需要大量資源與時間來建模，故放棄。
- **Gradient Boosting** 首次達到 baseline 效能，因此進一步使用 **XGBoost** 優化模型。

4.2 XGBoost 最終模型與參數

本文最佳參數選擇方式是每次挑選一個變數並指定一個其適合的參數空間，固定其他變數的參數，然後使用 5-fold CV 來得到 macro f1-score，挑選最佳者為此變數的參數。並且對每一個參數做同樣的步驟。以下是得到的參數，以及相對應的意義。

```
thres = 0.75  # 若 1 - 預測機率 > 0.75 則分類為「沒有糖尿病」

params <- list(
  objective = "binary:logistic",      # 二元分類問題
  eval_metric = "logloss",            # 評估指標為 log-loss
  eta = 0.01,                        # 學習率小，提升穩定性
  max_depth = 12,                     # 每棵樹最大深度
  subsample = 0.66,                  # 每棵樹使用 66% 資料
  min_child_weight = 20,            # 葉節點最少樣本數，控制複雜度
  colsample_bytree = 0.33,          # 每棵樹使用 33% 特徵
  lambda = 3.5,                       # L2 正則化強度 (Ridge)
  alpha = 1.5                         # L1 正則化強度 (Lasso)
)
fit_xgb <- xgb.train(
  params = params,
  data = dtrain,
  nrounds = 1000,                    # 決定使用 1000 棵樹
  watchlist = list(train = dtrain),
  verbose = FALSE)
```

- 使用 threshold = 0.75 以減少將糖尿病患者預測為「健康」的可能。

五、困難與未來方向

5.1 實作困難

- **資料不平衡問題**：預測機率若直接以 0.5 分類會導致偏差，需調整 threshold。
- **演算法訓練耗時**：如 Random Forest 與神經網路，參數調整與交叉驗證耗時冗長，因此未花過多時間在這些模型上。
- **特徵轉換失效**：嘗試進行 log-transform，結果在模型中表現無提升，反而增加前處理複雜度。

5.2 未來方向

- 可以探索 SMOTE 或類似的技術來處理不平衡資料以提升模型表現。
- 增加模型評估指標，如 Precision-Recall AUC，以避免僅依賴 Macro-F1。

六、參考文獻

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and regression trees*. Belmont, CA: Wadsworth International Group.

Breiman, L. (2001). Random forests. *Machine learning*, *45*(1), 5–32.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of statistics*, *29*(5), 1189–1232.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). New York, NY: ACM.